NLTK 자연어 처리 패키지

1692047 원진

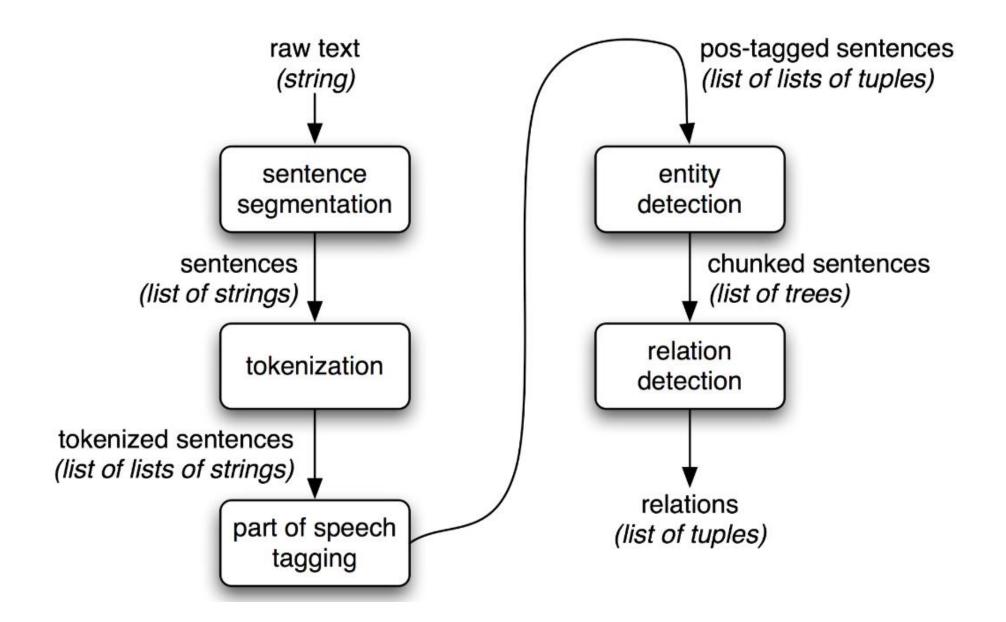
설치

Mac / Unix

```
    install NLTK run sudo pip install -U nltk
    install Numpy (optional) run sudo pip install -U numpy
    test installation run python then type import nltk
```

Windows

Information Extraction Architecture



토큰 생성

 token
 긴 문자열을 분석을 위한 작은 단위로 나눈 것.

 tokenizer
 문자열을 토큰으로 분리하는 함수, 토큰 문자열의 리스트를 반환한다.

sent_tokenize(text, language = 'english')

```
import nltk
corpus = 'hello, my name is jin! nice to meet you.'
print(nltk.sent_tokenize(corpus))

['hello, my name is wonjin!', 'nice to meet you.']
```

word_tokenize(text, language='english', preserve_line=False)

```
import nltk
corpus = 'hello, my name is jin! nice to meet you.'
print(nltk.word_tokenize(corpus))

['hello', ',', 'my', 'name', 'is', 'jin', '!', 'nice', 'to', 'meet', 'you', '.']
```

토큰 생성

• 영문의 경우 정규 표현식을 쓸 수 있다.

```
import nltk

corpus = 'hello, my name is jin! nice to meet you.'

retokenize = nltk.tokenize.RegexpTokenizer("[\w]+")
retokenize.tokenize(corpus)

print(retokenize.tokenize(corpus))

['hello', 'my', 'name', 'is', 'jin', 'nice', 'to', 'meet', 'you']
```

형태소 분석

형태소 (morpheme)

언어학에서 일정한 의미가 있는 가장 작은 말의 단위. 보통 자연어 처리에서는 토큰으로 형태소를 이용함.

형태소 분석 (morphological analysis)

- 어간 추출 (stemming)
- 원형 복원 (lemmatizing)
- 품사 부착 (Part-Of-Speech tagging)

단어로부터 어근, 접두사, 접미사, 품사 등다양한 언어적 속성을 파악하고,이를 이용하여형태소를 찾아내거나 처리하는 작업.

형태소 분석 - 어간 추출 (stemming)

변화된 단어의 접미사나 어미를 제거하여 같은 의미를 가지는 형태소의 기본형을 찾는 방법. 원형을 정확히 찾아주지는 않는다.

• PorterStemmer A word stemmer based on the Porter stemming algorithm.

```
import nltk

words = ['lives', 'crying', 'flies', 'dying']

st = nltk.stem.PorterStemmer()
print([st.stem(w) for w in words])

['live', 'cri', 'fli', 'die']
```

• LancasterStemmer A word stemmer based on the Lancaster (Paice/Husk) stemming algorithm.

```
import nltk

words = ['lives', 'crying', 'flies', 'dying']

st = nltk.stem.LancasterStemmer()
print([st.stem(w) for w in words])
['liv', 'cry', 'fli', 'dying']
```

형태소 분석 - 원형 복원 (lemmatizing)

같은 의미를 가지는 여러 단어를 사전형으로 통일하는 작업. 품사(part of speech)를 지정하는 경우 좀 더 정확한 원형을 찾을 수 있다.

wordnet 패키지를 추가로 다운받아야 함.

```
>>> import nltk
>>> nltk.download('wordnet')
```

```
import nltk

words = ['lives', 'crying', 'flies', 'dying']

lm = nltk.stem.WordNetLemmatizer()
print([lm.lemmatize(w) for w in words])
```

```
['life', 'cry', 'fly', 'dying']
```

```
import nltk

words = ['lives', 'crying', 'flies', 'dying']

lm = nltk.stem.WordNetLemmatizer()
print(lm.lemmatize("dying", pos="v"))
```

die

낱말을 문법적인 기능이나 형태, 뜻에 따라 구분한 것. NLTK에서는 Penn Treebank Tagset을 이용함.

TAG	DESCRIPTION	EXAMPLE
CC	conjunction, coordinating	and, or, but
CD	cardinal number	five, three, 13%
DT	determiner	the, a, these
EX	existential there	<u>there</u> were six boys
FW	foreign word	mais
IN	conjunction, subordinating or preposition	of, on, before, unless
JJ	adjective	nice, easy
JJR	adjective, comparative	nicer, easier
JJS	adjective, superlative	nicest, easiest
LS	list item marker	
MD	verb, modal auxillary	may, should

TAG	DESCRIPTION	EXAMPLE	
NN	noun, singular or mass	tiger, chair, laughter	
NNS	noun, plural	tigers, chairs, insects	
NNP	noun, proper singular	Germany, God, Alice	
NNPS	noun, proper plural	we met two <u>Christmases</u> ago	
PDT	predeterminer	<u>both</u> his children	
POS	possessive ending	<i>'S</i>	
PRP	pronoun, personal	me, you, it	
PRP\$	pronoun, possessive	my, your, our	
RB	adverb	extremely, loudly, hard	
RBR	adverb, comparative	better	
RBS	adverb, superlative	best	
RP	adverb, particle	about, off, up	
SYM	symbol	%	

TAG	DESCRIPTION	EXAMPLE
ТО	infinitival to	what <u>to</u> do?
UH	interjection	oh, oops, gosh
VB	verb, base form	think
VBZ	verb, 3rd person singular present	she <u>thinks</u>
VBP	verb, non-3rd person singular present	l <u>think</u>
VBD	verb, past tense	they <u>thought</u>
VBN	verb, past participle	a <u>sunken</u> ship
VBG	verb, gerund or present participle	<u>thinking</u> is fun
WDT	<i>wh</i> -determiner	which, whatever, whichever
WP	<i>wh</i> -pronoun, personal	what, who, whom
WP\$	<i>wh</i> -pronoun, possessive	whose, whosever
WRB	<i>wh</i> -adverb	where, when
-	punctuation mark, sentence closer	.;?*

TAG	DESCRIPTION	EXAMPLE
•	punctuation mark, comma	,
:	punctuation mark, colon	·
(contextual separator, left paren	(
)	contextual separator, right paren)

• pos_tag 단어 토큰에 품사를 부착하여 튜플로 출력함. averaged_perceptron_tagger 패키지를 추가로 다운받아야 함.

```
>>> import nltk
>>> nltk.download('averaged_perceptron_tagger')
```

```
import nltk

sentence = "Emma refused to permit us to obtain the refuse permit"
tagged_list = nltk.tag.pos_tag(nltk.word_tokenize(sentence))

print(tagged_list)

[('Emma', 'NNP'), ('refused', 'VBD'), ('to', 'TO'), ('permit', 'VB'), ('us', 'PRP'), ('to', 'TO'), ('obtain', 'VB'),
```

• 품사 태그 정보를 사용하면 명사인 토큰만 선택할 수 있다.

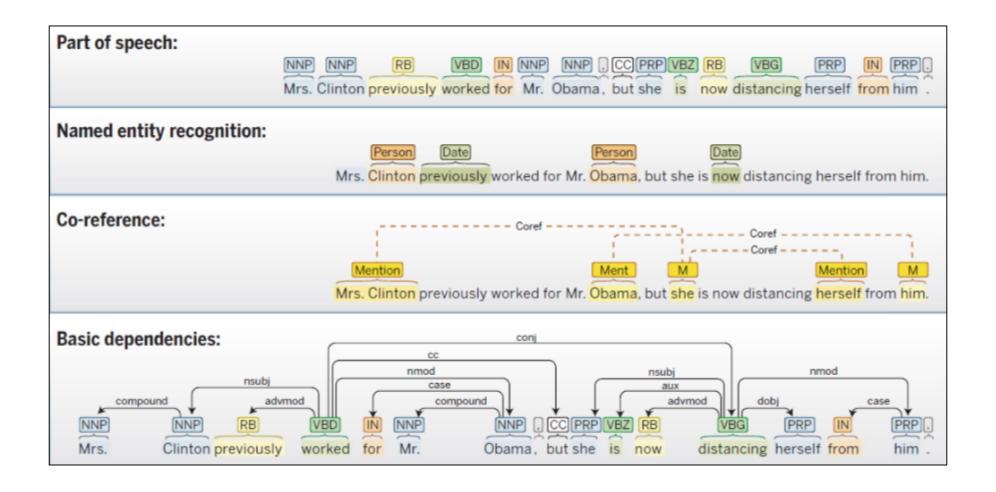
```
import nltk

sentence = "Emma refused to permit us to obtain the refuse permit"
tagged_list = nltk.tag.pos_tag(nltk.word_tokenize(sentence))

nouns_list = [t[0] for t in tagged_list if t[1] == "NN"]
print(nouns_list)

['refuse', 'permit']
```

어휘 분석 (Lexical Analysis)



Named Entity Recognition

개체 명 인식 (NER)

인명, 지명 등 고유 명사를 분류하는 방법론.

NE Type	Examples
ORGANIZATION	Georgia-Pacific Corp., WHO
PERSON	Eddy Bonte, President Obama
LOCATION	Murray River, Mount Everest
DATE	June, 2008-06-29
TIME	two fifty a m, 1:30 p.m.
MONEY	175 million Canadian Dollars, GBP 10.40
PERCENT	twenty pct, 18.75 %
FACILITY	Washington Monument, Stonehenge
GPE	South East Asia, Midlothian

NLTK에서 지원하는 기본 모듈로는 정확한 결과를 얻을 수 없다. 따라서 추가적인 데이터 셋을 확보해야 하며, 일반적으로 Stanford NER tagger가 사용된다.

Named Entity Recognition

Stanford NER Tagger

- Java JRE 8 이상 설치.
- JAVAHOME 환경변수 지정.
- dataset 경로 지정.

```
import nltk
import os
from nltk.tag.stanford import StanfordNERTagger

os.environ['JAVAHOME'] = "C:/Program Files/Java/jre1.8.0_191/bin/java.exe"

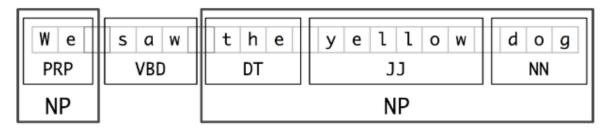
jar = './stanford-ner-3.9.2.jar'
model = './english.all.3class.distsim.crf.ser'

# Prepare NER tagger with english model
ner_tagger = StanfordNERTagger(model, jar, encoding='utf8')
```

Chunking

Chunk

구(phrase)로 묶어서 레이블을 지정함.



TAG	DESCRIPTION	WORDS	EXAMPLE
NP	noun phrase	DT+RB+JJ+NN + PR	the strange bird
PP	prepositional phrase	TO+IN	in between
VP	verb phrase	RB+MD+VB	was looking
ADVP	adverb phrase	RB	also
ADJP	adjective phrase	CC+RB+JJ	warm and cosy
SBAR	subordinating conjunction	IN	<u>whether</u> or not
PRT	particle	RP	<u>up</u> the stairs
INTJ	interjection	UH	hello